



Datenbanken

B-Baum, B*-Baum, B⁺-Baum

Dipl.-Inf. Robert Hartmann

Fachbereich Informatik (Sankt Augustin)

Juni 2024, KW 26

- 1 B-Baum (BAYER-Baum)
- 2 B⁺-Baum und B*-Baum
- 3 Darstellung B-Baum, B⁺-Baum und B*-Baum
- 4 Algorithmus zum Einfügen in einen B-Baum
- 5 Algorithmus zum Löschen aus einem B-Baum
- 6 Beispiel B-Baum, B⁺-Baum und B*-Baum

B-Baum (BAYER-Baum)

B für **Bayer**, **balanced** (=ausgeglichen, ausgewogen), **Boeing**, ...

Fakt (Bayer-Baum)

Ein B-Baum (1972 von RUDOLF BAYER und ED MCCREIGHT, im Boeing Scientific Research Lab) ist ein höhenbalancierter Baum, bei dem alle Blätter auf gleichem Niveau liegen.

Fakt

Der B-Baum erwies sich als ideale Datenstruktur zur Verwaltung von Indizes für das relationale Datenbankmodell, das 1970 von EDGAR F. CODD entwickelt wurde. Diese Kombination führte zur Entwicklung des ersten SQL-Datenbanksystems System R bei IBM.

Fakt

Jeder innere Knoten eines B-Baum enthält Suchschlüssel und zugehörige Datenwerte, sowie Verweise auf nachfolgende Knoten.

Ursprüngliche Definition (B-Baum)

Ein B-Baum heißt von der **Klasse m** , wenn gilt

- Jeder Knoten enthält höchstens $2m$ Schlüssel.
- Jeder Knoten mit Ausnahme des Wurzelknoten enthält mindestens m Schlüssel.
- Ein Knoten mit k Schlüsseln hat genau $k + 1$ Nachfolger oder keinen Nachfolger.
- Alle Knoten, die keine Nachfolger haben, sind Blätter auf gleichem Niveau.
- (Suchbaumeigenschaft): Sind s_1, s_2, \dots, s_k mit $m \leq k \leq 2m$ die Schlüssel eines Knotens x , dann sind alle Schlüssel des ersten Nachfolgers von x kleiner als s_1 , alle Schlüssel des $(k + 1)$ -ten Nachfolgers größer als s_k und alle Schlüssel des i -ten Nachfolgers, $1 < i < k + 1$, größer als s_{i-1} und kleiner als s_i .

Suchen im B-Baum der Klasse m mit n Knoten liegt in der Komplexitätsklasse $\mathcal{O}(m \cdot \log_{2m+1}(n))$.

Definition (B-Baum)

Ein B-Baum heißt von der **Ordnung** n , wenn gilt

- Alle Blätter besitzen gleiches Niveau.
- Jeder Knoten mit Ausnahme der Wurzel besitzt mindestens $\lceil \frac{n}{2} \rceil$ Nachfolger und höchstens n Nachfolger.
- Die Wurzel besitzt mindestens 2 und höchstens n Nachfolger.
- Jeder Knoten mit k Nachfolgern enthält $k - 1$ Schlüssel.
- (Suchbaumeigenschaft) wie zuvor.

Dadurch sind mehr Bäume erfasst; so lassen sich die B-Bäume der Ordnung 3, die so genannten 2-3-Bäume (HOPCROFT, 1970) definieren, was mit der ursprünglichen Definition nicht möglich ist, da hier – beim 2-3-Baum – die maximale Anzahl von Schlüsseln in einem Knoten ungerade ist.

Der B-Baum der Ordnung 4, auch bekannt als 2-3-4-Baum, lässt sich sehr leicht durch binäre Bäume, die *Rot-Schwarz-Bäume*, implementieren.

Unterschied zu B-Bäumen


- B^{*}-Baum (DONALD ERVIN KNUTH, 1973): innere Knoten zu $\frac{2}{3} = 66\%$ gefüllt bei B-Baum mindestens $\frac{1}{2}$. Im Reiser4 Dateisystem werden Blätter des B^{*}-Baums mit linearer Liste verbunden.
- B⁺-Baum : Datenelemente nur in Blattknoten. Innere Knoten enthalten Suchschlüssel und Verweise auf Nachfolger. Im NTFS Dateisystem werden die Blätter des B⁺-Baums mit linearer Liste verbunden.

Keine allgemein gültige Benamung.


Der B⁺-Baum wird aus historischen Gründen manchmal auch als B^{*}-Baum bezeichnet.

Darstellung B–Baum, B⁺–Baum und B^{*}–Baum

B–Baum, B^{*}–Baum



B⁺–Baum




- ① Füge anfangs in ein leeres Feld der Wurzel ein
- ② Die ersten n Werte (d.h. Suchschlüssel mit Daten) werden sortiert als Separatoren in die Wurzel eingetragen
- ③ Der nächste Wert, das ist der $(n + 1)$ -te, passt nicht mehr in die Wurzel und erzeugt einen **Überlauf** (overflow).
- ④ Die Wurzel wird **geteilt** mit der *Split*-Operation:
 - Jeder der beiden Kinder bekommt $\lfloor \frac{n}{2} \rfloor$ Werte.
 - Die Wurzel bekommt den **Median** der $(n + 1)$ Werte als Separator eingetragen.
- ⑤ Neue Werte (= Schlüssel, Daten) werden in den Blättern sortiert gespeichert.

- ⑥ Läuft ein Blatt über, d.h. der $(n + 1)$ -te Eintrag müsste gemacht werden, wird ein Splitt durchgeführt:
 - Das Blatt wird geteilt \Rightarrow 2 neue Blätter mit je $\lfloor \frac{n}{2} \rfloor$ Einträgen.
 - Diese werden mit dem Elternknoten anstelle des ursprünglichen Blattes verbunden.
 - Der **Median** der $(n + 1)$ Werte wird als Separator in den Elternknoten eingetragen.
- ⑦ Ist auch dieser Elternknoten voll, wird das Splitten fortgesetzt, im schlimmsten Fall bis zur Wurzel.


- ① Sei x das zu löschende Element. Sei k die minimal nötige Knotenbelegung.
- ② Suche x . (Graphtraversierung, vgl. „Programmieren 2“, „Algorithmen, Datenstrukturen, Graphentheorie“)
- ③ unterscheide 2 Fälle:
 - x ist in einem Blatt:
 - Verbleiben mindestens k Werte nach dem Löschen im Blatt
⇒ okay
 - Verbleiben im Blatt $k - 1$ Werte (also zuwenig) und ein direktes Nachbarblatt besitzt mehr als k Werte
⇒ Rotation (also Füllungsausgleich).
 - Sonst Blätter werden verschmolzen
⇒ Merge

- x ist in einem inneren Knoten:
 - Ersetze x durch den nächstgrößeren oder nächstkleineren Wert (bezogen auf den Suchschlüssel) aus dem linken bzw. rechten Nachfolgeknoten.
 - Lösche den gerade gewählten Wert aus dem entsprechenden Knoten.
⇒ (Rekursion!)




Beispiel B–Baum, B⁺–Baum und B^{*}–Baum (I)



Beispiel B–Baum, B⁺–Baum und B^{*}–Baum (II)



Beispiel B–Baum, B⁺–Baum und B^{*}–Baum (III)



Beispiel B–Baum, B⁺–Baum und B^{*}–Baum (IV)

