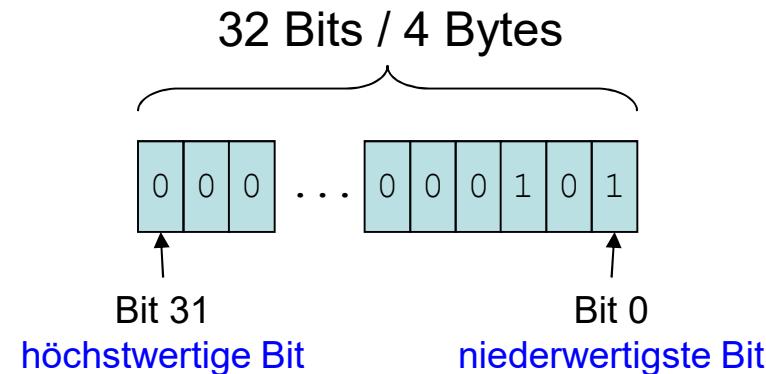


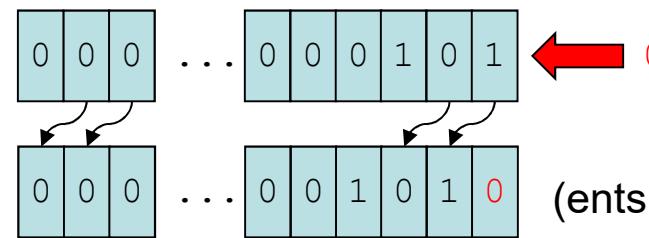
# Bitoperationen

```
int x = 5;
```



**Links-Shift** um eine Position

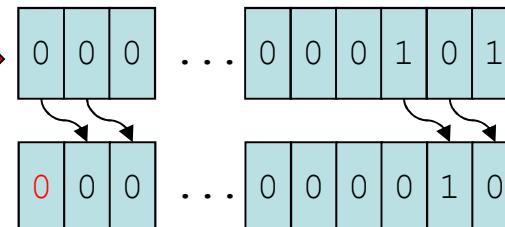
ergibt



(entspricht dem Wert  $10_{10}$ )

## Rechts-Shift um eine Position

ergibt



(entspricht dem Wert  $2_{10}$ )



# Bitoperationen

Operator	Beispiel	Wert Beispiel	Wirkung
$\sim$	$\sim 0$	-1	Bitweise Negation $\sim 0 \dots 000_2 = 1 \dots 111_2 = -1_{10}$
$<<$	$1 << 2$	4	Shiften nach links $0 \dots 01_2 << 2 = 0 \dots 0100_2 = 4_{10}$
$>>$	$-4 >> 2$	-1	Shiften nach rechts mit Vorzeichenbehandlung $11 \dots 1100_2 >> 2 = 111 \dots 111_2$
$>>>$	$-4 >>> 2$	1073741823	Shiften nach rechts (0 wird eingeschoben) $1 \dots 1100_2 >>> 2 = 0011 \dots 111_2 = 1073741823_{10}$
$\&$	$9 \& 3$	1	Bitweises Und $0 \dots 01001_2 \& 0 \dots 00011_2 = 0 \dots 01_2 = 1_{10}$
$ $	$9   3$	11	Bitweises Oder $0 \dots 01001_2   0 \dots 00011_2 = 0 \dots 01011_2 = 11_{10}$
$^$	$9 ^ 3$	10	Exlusives Oder $0 \dots 01001_2 ^ 0 \dots 00011_2 = 0 \dots 01010_2 = 10_{10}$

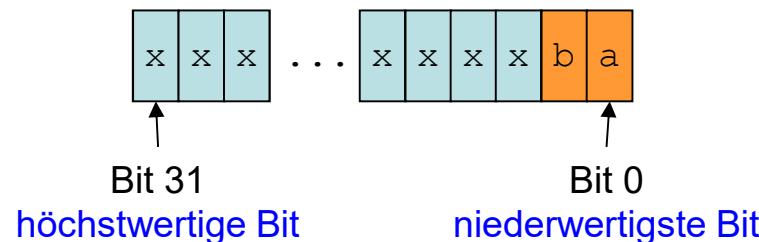
- **Shiften:** von einer Seite 0-Bits reinschieben, auf der anderen Seite fallen entsprechend viele Bits raus
- **mit Vorzeichenbehandlung:** eingeschobene Bits entsprechend ursprünglich höchsten Bit (0 oder 1)



# Beispiel

- **Aufgabenstellung:** gebe den Wert der beiden letzten / niederwertigen Bits eines int-Wertes aus
  - **Idee:** isoliere ein Bit und gebe dann den Wert dieses Bits aus (0 oder 1)

```
int zahl;
```



- Programmieransatz:
    - Schritt 1: `zahl & 0x1` liefert den Wert des 0. Bits  $a$  (0 oder 1)
    - Schritt 2: `zahl >> 1` schiebt alle Bits eine Position nach rechts.  
Dadurch wird das ursprünglich zweite Bit  $b$  das neue niederwertigste Bit  
(und damit Situation wie bei Schritt 1)
    - Schritt 3: `zahl & 0x1` liefert den Wert des Bits  $b$  (0 oder 1)
  - In der Operation `zahl & 0x1` nennt man `0x1` eine **Bit-Maske**



# Java-Programm zum Beispiel

```
public class Bitwerte {
    public static void main(String[] args) {
        // Beispielwert
        int wert = -1234567;
        // hierher wird jeweils das Bit extrahiert
        int bitWert;

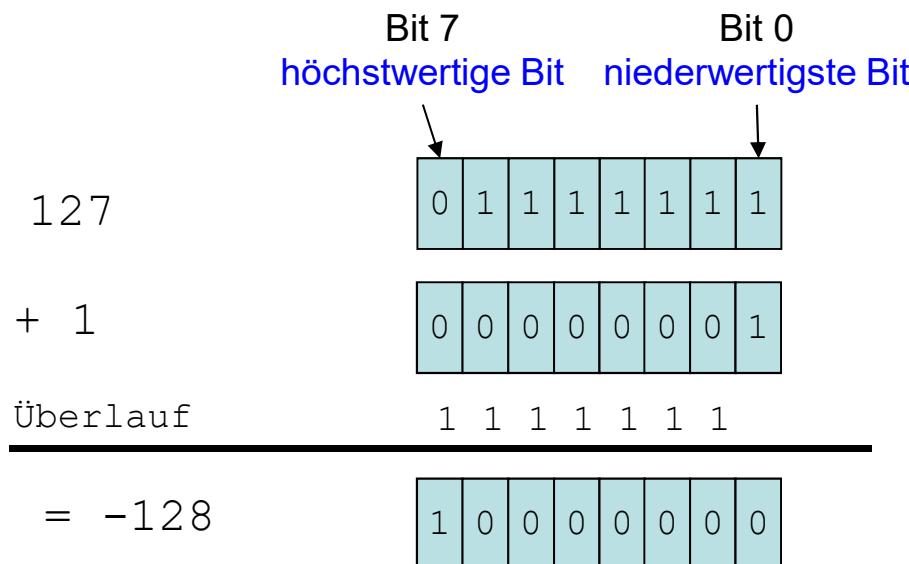
        //----- 1. Bit behandeln -----
        // alle anderen Bits ausser unterstem Bit maskieren
        bitWert = wert & 0x1;
        // Bit-Wert ausgeben
        System.out.println("1.Bit hat den Wert " + bitWert);

        //----- 2. Bit behandeln -----
        // nach rechts shiften
        wert = wert >> 1;
        // alle anderen Bits ausser unterstem Bit maskieren
        bitWert = wert & 0x1;
        // Bit-Wert ausgeben
        System.out.println("2.Bit hat den Wert " + bitWert);
    }
}
```



# Überlauf

- Das Rechnen mit ganzzahligen Werten liefert **immer exakte Resultate!**
  - **Ausnahme: Überlauf**
  - Hier am Beispiel des Datentyps `byte` mit 8 Bits:



- Die Arithmetik mit ganzzahligen Werten ignoriert einen Überlauf
  - Es liegt in der Verantwortung eines Programmierers, dies zu vermeiden!

# Zwischenstand

- Ganzzahlige Typen werden auch zur Darstellung von Bitfolgen entsprechender Länge verwendet.
- Es gibt eine Reihe von Operationen, die bitweise auf einer solchen Bitfolge arbeiten.
- Ganzzahlige Operationen liefern immer das exakte Ergebnis
- Ausnahme: Bereichsüberlauf, bei dem stillschweigend weitergerechnet wird

## Reflektion

- Kann aus zwei positiven Zahlen und einer Operation auf ihnen durch Bereichsüberlauf eine negative Zahl entstehen?
- Kann aus zwei negativen Zahlen eine positive werden?
- Kann aus einer negativen und einer positiven eine negative/positive Zahl entstehen? Jeweils Beispiele?



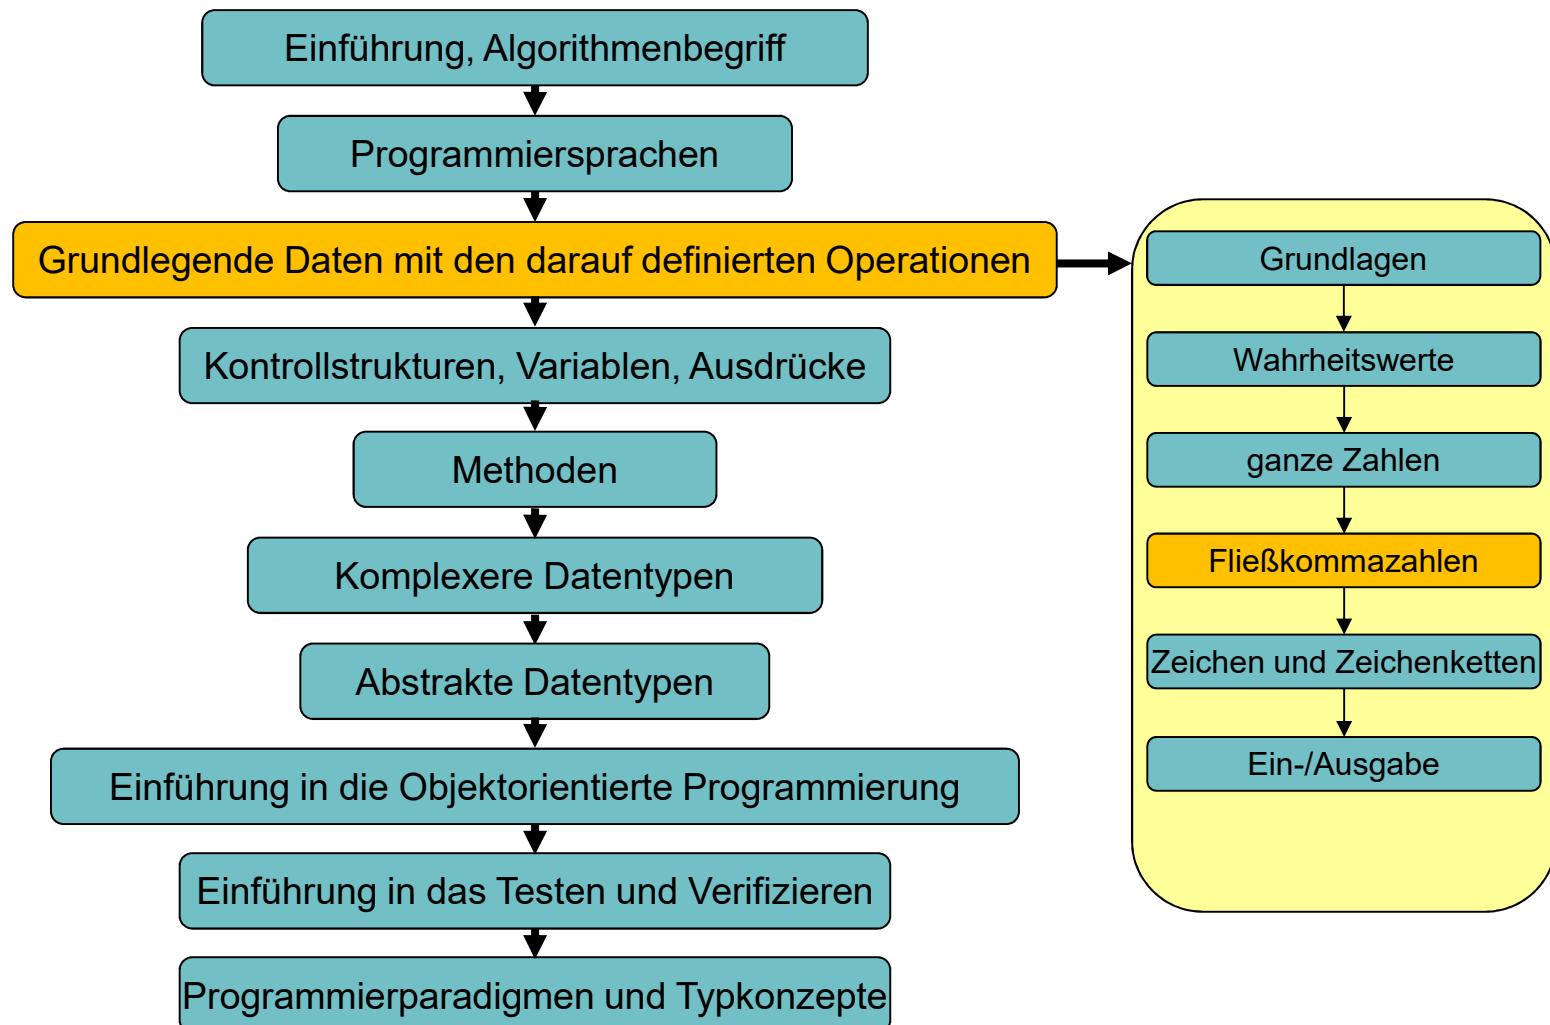
# Zusammenfassung

- Ebenso wie in der Mathematik gibt es auch in Programmiersprachen eine **Unterscheidung unterschiedlicher Zahlenmengen**
- Ganze Zahlen werden intern durch eine **Zweierkomplementdarstellung** repräsentiert
- Angabe von Konstanten in **dezimal**, **oktal** und **hexadezimal** (und seit Java 7 binär) möglich
- Division und Modulo mit ganzzahliger Bedeutung
- **Möglicher Überlauf** muss durch Programmierer vermieden werden
- **Steckbrief ganze Zahlen in Java**

Name	byte, short, int, long
Wertemenge	Teilmenge der ganzen Zahlen
Kodierung	1,2,4,8 Bytes mit Zweierkomplementdarstellung
Konstanten	Dezimalzahlen, Oktalzahlen, Hexadezimalzahlen
Operationen	+ , - , * , / , % , ...
Nutzung	für ganze Zahlen und Bitfolgen
Besonderheiten	Berechnungen alle exakt bis auf Überlauf



# Inhalt dieser Veranstaltung



# Reelle Zahlen

- Wie lassen sich **reelle Zahlen** darstellen?
- Zur Erinnerung:
  - n Bits ergeben genau  $2^n$  verschiedene Werte
  - Im Dezimalsystem steht  $12,34$  für die Zahl  $1 \cdot 10^1 + 2 \cdot 10^0 + 3 \cdot 10^{-1} + 4 \cdot 10^{-2}$
  - Allgemein für Basis B:
- Erster Ansatz:
  - Teile die verfügbaren n Bits auf in einem Vorkommaanteil und einen Nachkommaanteil
  - Vor- und Nachkommaanteil enthält Koeffizienten für Zweierpotenzen
- Beispiel:  $011,110_2 = \sum_{i=0}^2 z_i \cdot 2^i + \sum_{j=1}^3 d_j \cdot 2^{-j}$ 
$$= (0 \cdot 2^2 + 1 \cdot 2^1 + 1 \cdot 2^0) + (1 \cdot 2^{-1} + 1 \cdot 2^{-2} + 0 \cdot 2^{-3})$$
$$= (0 + 2 + 1) + (0,5 + 0,25 + 0)$$
$$= 3,75_{10}$$



# Halblogarithmische Schreibweise

- Nachteil des ersten Ansatzes: feste Aufteilung in  $n_1$  Bits für Vorkommaanteil und  $n_2$  Bits für Nachkommaanteil
- Beispiel:  $n=16$ ,  $n_1=8$ ,  $n_2=8$ : nur Zahlen im Bereich (128,-129) darstellbar
- Idee: halblogarithmische Schreibweise wie etwa  $+6,02 \cdot 10^{23}$
- Allgemeines Format für solch eine Darstellung zu einer Basis B:
  - Vorzeichen V (Beispiel oben: 0 für +, 1 für -)
  - Mantisse M (Beispiel oben: 6,02)
  - Exponent E (Beispiel oben: 23)
  - $\text{wert}(V, M, E)_B = (-1)^V \cdot M \cdot B^E$
- Eine Mantisse  $M \neq 0$  zu einer Basis B heißt normalisiert, wenn  $1 \leq |M| < B$ , d.h. die Darstellung hat z.B. für  $B=2$  eine Form  $1, d_1 \dots d_m$ .
- Darstellung einer reellen Zahl in halblogarithmischer Schreibweise und normalisierter Mantisse nennt man Fließkommazahl (oder Gleitkommazahl)



# Darstellungsgenauigkeit

- Für m Bits und eine normalisierte Mantisse  $d_1 \dots d_m$  zur Basis 2 kann man als Zahl darstellen  $d_1 \cdot 2^{-1} + d_2 \cdot 2^{-2} + \dots + d_m \cdot 2^{-m}$
- Konsequenzen:
  - Durch die Beschränkung auf m Bits in der Mantisse ist die **Genauigkeit beschränkt**, mit der man eine reelle Zahl darstellen kann (Beispiel s.u.)
  - Der **maximale Rundungsfehler** beträgt  $2^{-(m+1)}$
  - Nur reelle Zahlen, die sich als Summe von Zweierpotenzen zur Basis 2 darstellen lassen, **sind auch exakt darstellbar**
- Beispiel aus dem Dezimalsystem:  
Die Zahl  $0,123456_{10}$  lässt sich mit 4 erlaubten (Nachkomma-)Dezimalziffern annäherungsweise darstellen als  $0,1234_{10}$  oder  $0,1235_{10}$ , aber nicht exakt
- Aufgabe: Versuchen Sie die Zahl  $0,1_{10}$  als Summe von negativen Zweierpotenzen  $d_j \cdot 2^{-j}$  darzustellen!



# IEEE 754 Darstellungsformat

- Die Organisation IEEE hat im **Standard 754 mehrere Formate (und Anforderungen)** für **Fließkommazahlen** festgelegt, die in heutigen Prozessoren verwendet werden
- Die für uns wichtigsten sind die Spezifikationen für 32 und 64 Bits
- **32 Bit / 4 Bytes:**
  - 1 Bit Vorzeichen, 8 Bit Exponent, 23 Bit Mantisse
  - Mit  $m=23$  ergibt sich ein maximaler Rundungsfehler von  $2^{-(23+1)} \approx 5,96 \cdot 10^{-8}$  oder **7 signifikante Dezimalnachkommastellen**
- **64 Bit / 8 Bytes:**
  - 1 Bit Vorzeichen, 11 Bit Exponent, 52 Bit Mantisse
  - Mit  $m=52$  ergibt sich ein maximaler Rundungsfehler von  $2^{-(52+1)} \approx 9 \cdot 10^{-15}$  oder **14 signifikante Dezimalnachkommastellen**



# Besonderheiten zur Norm IEEE 754

- Mantisse
  - Die Mantisse wird in einer normalisierten Darstellung zur Basis 2 gespeichert, so dass genau eine 1 vor dem Komma steht (außer für die Zahl 0 ist dies immer möglich)
  - Von der normalisierten Mantisse wird die **erste Ziffer in der Darstellung weggelassen** (weil sie ja immer 1 ist außer bei der Zahl 0)
- Der **Exponent wird im Excess-127 Code dargestellt**
  - Excess-127 Code: für eine Zahl  $x$  ist die Darstellung im Excess-127 Code die Zahl  **$x+127$  in Dualdarstellung**  
Beispiel  $x=5$ :  $5+127 = 132_{10} = 10000100_2$
  - Diese Excess-127 Darstellung hat **Vorteile beim Vergleich** von IEEE 754 Zahlen in Prozessoren



# Zwischenstand

- Halblogarithmische Schreibweise erlaubt die Darstellung auch größerer Zahlenbereiche (kleiner Vorkommaanteil und großer Nachkommaanteil oder großer Vorkommaanteil und kleiner Nachkommaanteil)
- Nicht alle Zahlen sind mehr exakt darstellbar
- In Prozessoren wird die IEEE-754-Darstellung verwandt

## Reflektion

- Erläutern Sie mit eigenen Worten, was die Vorteile und Nachteile einer halblogarithmischen Darstellung (bei einer festen Stellenzahl) sind.



# Umwandlung einer reellen Zahl

- **Schritt 1:** Darstellung der reellen Zahl als Dualzahl mit Vorzeichen, getrennt mit Dualzahlvorkommaanteil und einem Dualzahlnachkommaanteil  
Beispiel:  $5,125_{10} = 101,001_2$   
weil  $5_{10} = 101_2$  und  $0,125_{10} = 0 \cdot 0,5_{10} + 0 \cdot 0,25_{10} + 1 \cdot 0,125_{10} = 0,001_2$
- **Schritt 2:** Normalisierung der Mantisse, so dass genau eine 1 vor dem Komma steht ("Verschieben des Kommas")  
Beispiel:  $101,001_2 \rightarrow 1,01001_2$
- **Schritt 3:** Anpassen des Exponenten, so dass die Kommaverschiebung wertmäßig wieder ausgeglichen wird  
Beispiel:  $101,001_2 = 1,01001_2 \cdot 2^2$
- **Schritt 4:** Kodierung des Exponenten im Excess-127 Code  
Beispiel: 2 im Excess-127 Code:  $127_{10} + 2_{10} = 129_{10} = 10000001_2$
- **Schritt 5:** Zusammensetzung der Darstellung in **Vorzeichen**, **Exponent**, Mantisse (ohne führende 1) entsprechend der Darstellungsform (32/64 Bit)  
Beispiel (32 Bit): **0** **10000001** **010010...000**



# Darstellungsbedingte Probleme

- Das Beispiel zur Problematik wird im Dezimalsystem gegeben
- Annahme im Beispiel:
  - Mantissenlänge 3 (Dezimal-)Ziffern
  - Addition der beiden Zahlen in normalisierter Mantisse  $1,234 \cdot 10^1$  und  $9,999 \cdot 10^3$
- (Interne) Schritte bei der Addition:
  - Anpassen der Werte auf gleichen größeren Exponenten  $0,01234 \cdot 10^3$  und  $9,999 \cdot 10^3$ . Aufgrund der Mantissenbeschränkung kann dies aber nur als  $0,012 \cdot 10^3$  und  $9,999 \cdot 10^3$  intern dargestellt werden!
  - Addition der Werte:  $0,012 \cdot 10^3 + 9,999 \cdot 10^3 = 10,011 \cdot 10^3$
  - Normalisierung der Mantisse:  $1,001 \cdot 10^4$
  - Korrekter Wert wäre  $1,001134 \cdot 10^4$
- Solche Probleme können auftreten bei
  - Operationen wie Addition auf Zahlen sehr unterschiedlicher Größe
  - Subtraktion fast gleicher Zahlen
  - Division durch Werte nahe 0



# Fließkommazahlen in Java

Datentyp	Anzahl Bits	Anzahl Bytes	Wertebereich
float	32	4	ca. $-3,4 \cdot 10^{38}$ bis $+3,4 \cdot 10^{38}$
double	64	8	ca. $-1,8 \cdot 10^{308}$ bis $1,8 \cdot 10^{308}$

- **Übereinkunft:** wenn nichts dagegen spricht (zu hoher Speicherbedarf), nimmt man im Programm für reelle Werte den **Datentyp double**
- **Konstanten** sind vom Typ double
- Viele **mathematische Funktionen** erwarten als Argument und liefern als Resultat Werte vom Typ double



# Fließkommakonstanten

- Fließkommakonstanten haben, gegenüber einer dezimalen Ganzzahldarstellung, wenigstens eines (oder eine Kombination) von:
  - einen **Dezimalpunkt** (kein Komma!) mit nichtleerem Vorkommaanteil oder nichtleerem Nachkommaanteil oder beides
  - einen **Exponentteil** der Form `e` oder `E` gefolgt von einer int-Konstanten, wobei der Exponent zur Basis 10 angegeben wird (eine Angabe `Ex` entspricht  $\cdot 10^x$ )
  - einen **Fließkommasuffix** `f` / `F` (float) oder `d` / `D` (für double)
- Wird kein Suffix `f/F` angegeben, so ist die Konstante vom Typ `double`
- Beispiele:
  - `0.3`, `.3`, `3.`
  - `3E2`, `.3E2` `3.0E2`
  - `3f`, `3D`, `3.0f`, `3.e3f`, `3.0e-3f`



# Arithmetische Operationen mit Fließkommawerten

Operator	Beispiel	Wert Beispiel	Wirkung
+	+3.0	+3.0	Vorzeichenplus
-	-3.0	-3.0	Vorzeichenminus
+	2.0 + 4.0	6.0	Addition
-	4.0 - 2.0	2.0	Subtraktion
*	2.0 * 2.0	4.0	Multiplikation
/	8.0 / 2.0	4.0	Division (nicht ganzzahlig)
%	9.0 % 2.0	1.0	Rest bei Division (Modulo)



# Beispiel

```
public class FloatBeispiel {  
    public static void main(String[] args) {  
  
        float f1, f2;  
        double d1, d2;  
  
        // Fliesskommakonstanten des Typs float haben ein Suffix f  
        f1 = 0.1f;  
        f2 = 0.1f;  
        d1 = 0.1;  
        d2 = 0.1;  
  
        // Wir geben das Ergebnis einiger Operationen aus  
        System.out.println("f1 * f2: " + (f1 * f2));  
        System.out.println("d1 * d2: " + (d1 * d2));  
    }  
}
```

## Ausgabe (beides mathematisch falsch!):

f1 \* f2: 0.010000001  
d1 \* d2: 0.01000000000000002



# Vergleichsoperationen mit Fließkommawerten

Operator	Beispiel	Wert Beispiel	Wirkung
<	$3.0 < 4.0$	true	kleiner
$\leq$	$3.0 \leq 4.0$	true	kleiner oder gleich
>	$3.0 > 4.0$	false	größer
$\geq$	$5.0 \geq 3.0$	true	größer oder gleich
$\equiv$	$3.0 \equiv 4.0$	false	gleich (Achtung!)
$\neq$	$3.0 \neq 4.0$	true	ungleich (Achtung!)

- Diese Operationen liefern Ergebnis vom Typ boolean
- Der Test auf Gleichheit und Ungleichheit sollte bei Fließkommawerten nur mit Vorsicht angewandt werden
- Grund:  $0.1f == 0.099999999f$  ergibt true
- Statt dessen besser einen Test auf verschwindend geringen Abstand:  
 $\text{Math.abs}(x-y) < \text{toleranz}$   
für einen selbst gewählten und anwendungsabhängigen Wert von toleranz  
(zum Beispiel:  $1e-10$ )



# Weitere mathematische Operationen

Funktion	Beispiel	Wert Beispiel	Wirkung
Math.abs(x)	Math.abs(-3.0)	3.0	Absolutwert $ x $ einer Zahl
Math.ceil(x)	Math.ceil(3.1)	4.0	Aufrunden auf ganze Zahl
Math.floor(x)	Math.floor(3.1)	3.0	Abrunden auf ganze Zahl
Math.pow(x, y)	Math.pow(3.0, 2.0)	9.0	Potenz $x^y$
Math.sqrt(x)	Math.sqrt(9.0)	3.0	Quadratwurzel
Math.sin(x)	Math.sin(0.0)	0.0	Sinus
Math.cos(x)	Math.cos(0.0)	1.0	Cosinus
Math.tan(x)	Math.tan(0.0)	0.0	Tangens
Math.exp(x)	Math.exp(1.0)	2.71...	$e^x$
Math.log(x)	Math.log(1.0)	0.0	Logarithmus zur Basis e
Math.log10(x)	Math.log10(10.0)	1.0	Logarithmus zur Basis 10

## Zu beachten:

- die trigonometrischen Funktionen **arbeiten mit Radianwerten**
- Umwandlung von Grad x nach Radian y:  $y = x \cdot (\pi / 180)$
- Umwandlung von Radian y nach Grad x:  $x = y \cdot (180 / \pi)$
- Es gibt auch entsprechende Umwandlungsfunktionen in Math



# Zwischenstand

- Bei arithmetischen Operationen mit Fließkommawerten können erhebliche Probleme bzgl. der Genauigkeit des Resultats auftreten
- `float` und `double` dienen in Java der Darstellung von Fließkommazahlen
- Neben den Grundrechenarten gibt es eine Vielzahl von Operationen auf Fließkommazahlen (Taschenrechnerfunktionalität)
- Der Test auf (Un-)Gleichheit ist problematisch

## Reflektion

- Welche Toleranzangabe würde bei dem Test `Math.abs(x-y) < toleranz` prinzipiell Sinn machen, welche nicht (wieso)?  
1E10, 1E1, 1E-1, 1E-5, 1E-10, 1E-15, 1E-20, 1E-25, 1E-30, 1E-100, 1E-1000



# Beispiel

- Schiefer Wurf der Physik (ohne Luftreibung)
- Gegeben: Anfangsgeschwindigkeit  $v_0$ , Abstoßwinkel  $\alpha$
- Gesucht: Höhe  $y$  bei Entfernung  $x$
- Formel dazu ( $g=9,81 \text{ m/s}^2$ ):  $y = \tan(\alpha) \cdot x - \frac{g \cdot x^2}{2 \cdot (v_0 \cdot \cos(\alpha))^2}$

```
public class SchieferWurf {  
    public static void main(String[] args) {  
        double v0 = 30.0;                                // Anfangsgeschwindigkeit  
        double alpha = 45.0 * (Math.PI / 180.0); // Abschusswinkel  
        double g = 9.81;                                 // Erdschwerebeschleunigung  
        double x = 10.0;                                // gegebener x-Wert  
        double y;                                       // gesuchter y-Wert  
  
        // Berechnung der Formel  
        y = Math.tan(alpha)*x  
            - ((g * x*x) / (2.0 * Math.pow(v0 * Math.cos(alpha), 2.0)));  
  
        // Ausgabe des Ergebnisses  
        System.out.println("Höhe am Punkt " + x + " ist " + y);  
    }  
}
```



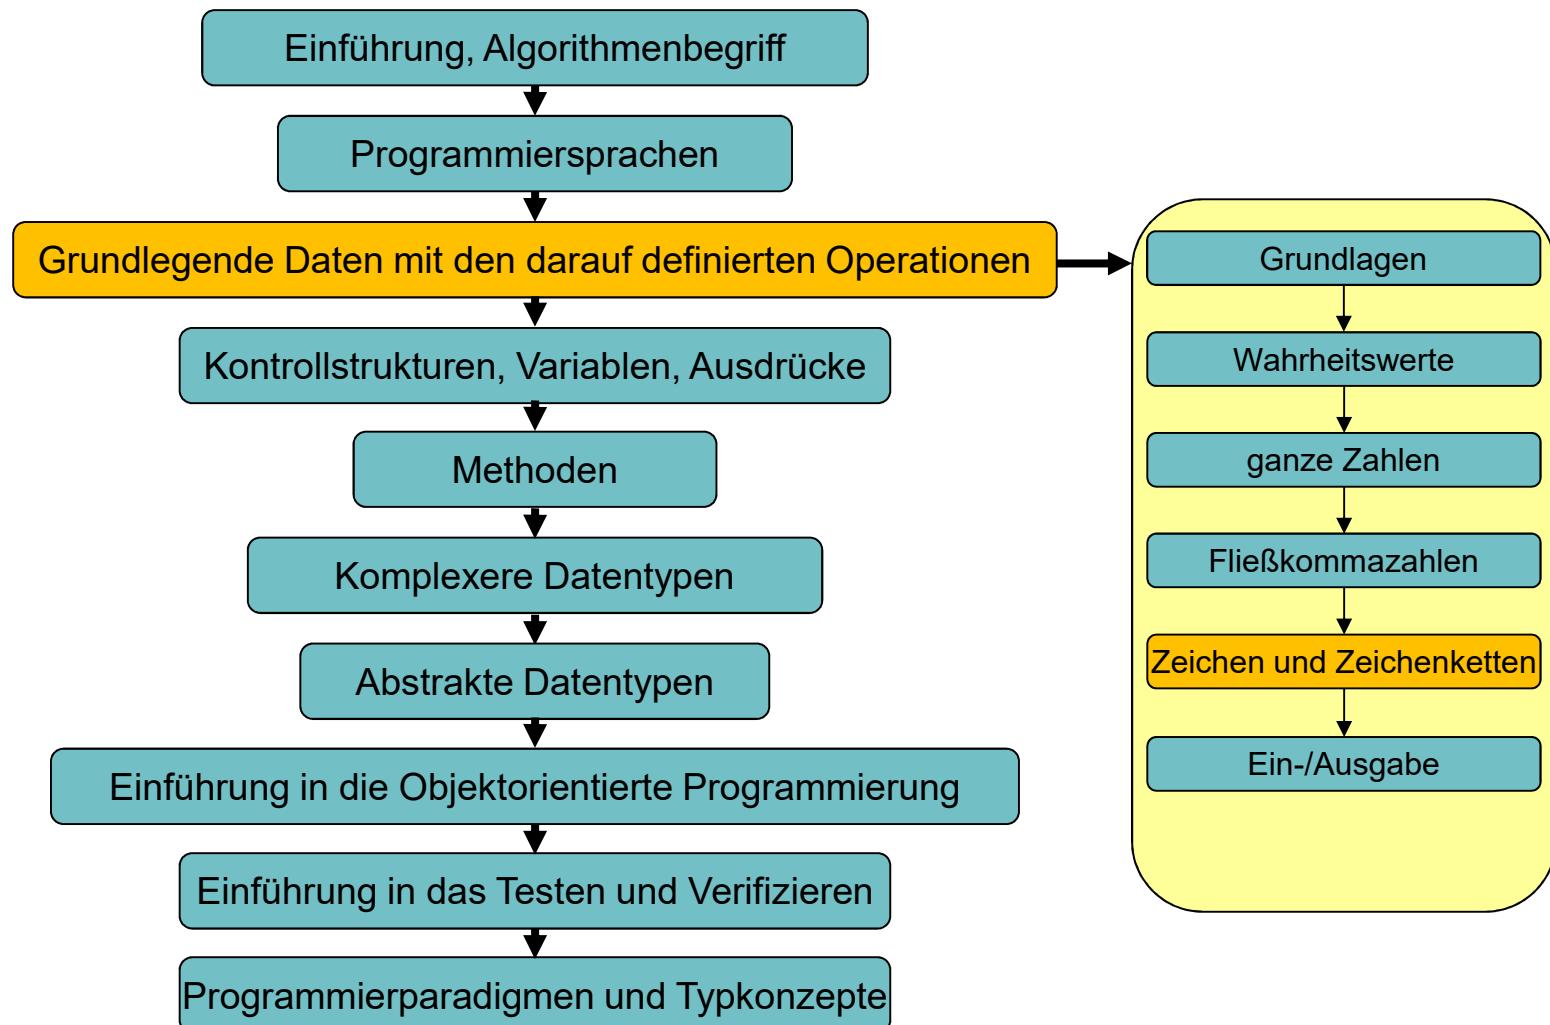
# Zusammenfassung

- Fließkommazahlen decken **Teile der reellen Zahlen** ab
- Selbst "einfache" reelle Zahlen wie 0,1 lassen sich **nicht exakt darstellen**
- Arithmetik **muss nicht exakt sein**, mathematische Gesetze gelten nicht unbedingt (Assoziativgesetz, Distributivgesetz)
- Steckbrief Fließkommazahlen

Name	float, double
Wertemenge	Teilmenge der reellen Zahlen
Kodierung	4 oder 8 Bytes, IEEE 854
Konstanten	Punkt- und/oder Exponentialteil mit optionalem Suffix
Operationen	+ , - , * , / , % , . . .
Nutzung	für reelle Zahlen
Besonderheiten	exakte Darstellung von Werten und exakte Arithmetik nicht garantiert



# Inhalt dieser Veranstaltung



# Buchstaben / Zeichen

- Nächste Frage: wie lassen sich **Buchstaben oder allgemein Zeichen** darstellen?
- Dazu zu klären: **welche Zeichen** sollen kodiert werden?
  - Buchstaben (Groß-/Kleinbuchstaben) des lateinischen Alphabets A,...,Z,a,...z
  - Ziffern 0,...,9
  - Interpunktionszeichen: ? ! . ; , : ...
  - sonstige Zeichen = + - § \$ ...
- **Auch Sonderzeichen:**
  - ä, ö, ü, ß, à, â,... ?
  - griechische Buchstaben
  - arabische Zeichen
  - chinesische Zeichen
  - ...



# Übersicht über die historische Entwicklung

- Die erste weit verbreitete Kodierung von Zeichen ist **ASCII** (American Standard Code for Information Interchange) aus dem Jahre 1966
- 7 Bits ( $2^7=128$  Möglichkeiten) zur Darstellung u.a. lateinischer Buchstaben sowie einiger Kontrollcodes (Zeilenende, Seitenende, Gong,...)
- Erweiterung **ISO-8859-1** mit insgesamt 8 Bit ( $2^8=256$  Möglichkeiten insgesamt) für europäische Zeichen ä,ö,ü,...
- 8-32 Bit **Unicode** als einheitliche Kodierung für alle Regionen
- **UCS** (Universal Character Set) als internationaler Standard der ISO
- Alle diese Kodierungen **erweitern die vorherigen Kodierungen (Obermenge)**



# ASCII

Oberste 3 Bits

Unterste 4 Bits

	<b>000</b>	<b>001</b>	<b>010</b>	<b>011</b>	<b>100</b>	<b>101</b>	<b>110</b>	<b>111</b>
<b>0000</b>	NUL	DLE	SPACE	0	@	P	_	p
<b>0001</b>	SOH	DC1	!	1	A	Q	a	q
<b>0010</b>	STX	DC2	"	2	B	R	b	r
<b>0011</b>	ETX	DC3	#	3	C	S	c	s
<b>0100</b>	EOT	DC4	\$	4	D	T	d	t
<b>0101</b>	ENQ	NAK	%	5	E	U	e	u
<b>0110</b>	ACK	SYN	&	6	F	V	f	v
<b>0111</b>	BEL	ETB	"	7	G	W	g	w
<b>1000</b>	BS	CAN	(	8	H	X	h	x
<b>1001</b>	HAT	EM	)	9	I	Y	i	y
<b>1010</b>	LF	SUB	*	:	J	Z	j	z
<b>1011</b>	VT	ESC	+	;	K	[	k	{
<b>1100</b>	FF	FS	,	<	L	\	l	
<b>1101</b>	CR	GS	-	=	M	]	m	}
<b>1110</b>	SO	RS	.	>	N	^	n	~
<b>1111</b>	SI	US	/	?	O	__	o	DEL



# Einige Eigenschaften der ASCII-Kodierung

- Groß- und Kleinbuchstaben sowie Ziffern sind jeweils aufeinanderfolgend in Blöcken angeordnet
- Durch Vergleich von Codes innerhalb eines Blocks kann man lexikografisch kleinere, größere und gleiche Zeichen ermitteln
- Einen Großbuchstaben kann ich in einen Kleinbuchstaben umwandeln, indem ich auf den Code 0x20 addiere  
**Beispiel:** das Zeichen A hat den Code  $100\ 0001_2 = 0x41$ , das Zeichen a hat den Code  $110\ 0001_2 = 0x61 = 0x41 + 0x20$
- Einen Kleinbuchstaben kann ich einen Großbuchstaben umwandeln, indem ich vom Code 0x20 abziehe  
**Beispiel:** das Zeichen a hat den Code  $110\ 0001_2 = 0x61$ , das Zeichen A hat den Code  $100\ 0001_2 = 0x41 = 0x61 - 0x20$
- Zu einer Ziffer kann ich den Wert dieser Ziffer ermitteln, indem ich vom Code den Code der Ziffer 0 abziehe  
**Beispiel:** Die Ziffer 0 hat den Code  $011\ 0000_2 = 0x30$ . Die Ziffer 9 hat den Code  $011\ 1001_2 = 0x39$ .  $0x39 - 0x30 = 9$



# ISO-8859-1 Erweiterung

- Problem (für uns): In der ASCII-Tabelle erscheinen zum Beispiel keine deutschen Umlaute oder æåôõ...
- Die ISO (International Organization for Standardization; <http://www.iso.org/>) hat verschiedene regionsspezifische Erweiterungen definiert.
- ISO-8859-1 (manchmal auch ISO Latin-1 genannt): Erweiterung um 128 Zeichen mit den Codes 128-255 für westeuropäische Zeichen (also von 7 Bit ASCII auf insgesamt 8 Bit)
- Für andere Regionen der Erde gab es ebenfalls 128 Erweiterungscodes, man musste sich also entscheiden, welche Erweiterung man nehmen wollte (Codepages)
- Wichtig: die ersten 128 Zeichen haben in jeder Regionserweiterung die gleiche Bedeutung (=ASCII)



# Unicode

- Bekanntlich sind in der Welt mehr als 256 Schriftzeichen bekannt
- Unicode (<http://www.unicode.org/>) ist eine **fortlaufende Entwicklung**, alle Schriftzeichen der Welt zu kodieren
- Mit Unicode 1.0 wurden zu Beginn **16 Bits** genutzt und damit  $2^{16}=65536$  Möglichkeiten definiert
- Mit neueren Unicode-Definitionen (Version 2 aufwärts) wurde **weiterer Raum geschaffen** (sogenannte Planes) und weitere (eher exotische) Zeichen definiert
- In der aktuellen Version sind alle Unicode-Zeichen mit 21 Bits darstellbar
- **Wichtig:** die ersten 256 Zeichen in Unicode haben die gleiche Kodierung wie ISO Latin-1 (inklusive ASCII)



# UCS

- UCS (Universal Character Set) ist ein internationaler Standard der ISO, der nahezu identisch mit Unicode ist (und gehalten wird)
- UCS-2 mit 2 Bytes entspricht Unicode 16 Bit (veraltet)
- UCS-4 mit 4 Bytes entspricht den neueren Erweiterungen von Unicode mit mehr als  $2^{16}$  Kodierungen (Erweiterungs-Planes). Nur 21 Bits davon sind (derzeit) relevant.



# UTF-8 (und UTF-16, UTF-32)

- **UTF-8** (Unicode Transformation Format) ist ein Format **auf Basis von Unicode / UCS zur speichereffizienten Darstellung** von Zeichen
- Wird genutzt u.a. zur Speicherung von Dokumenten und im Austausch von Daten im Internet (Mail, Browser,...)
- In UTF-8 haben Zeichenkodierungen **keine feste Byte-Länge**, sondern diese kann je nach Zeichen zwischen 1 und 4 Bytes variieren
- **Idee:** häufig genutzte Zeichen mit sehr wenigen Bytes kodieren, selten genutzte Zeichen mit mehr Bytes
- **Alle ASCII-Zeichen** und damit alle lateinischen Groß-/Kleinbuchstaben und Ziffern lassen sich **mit 1 Byte speichern**
- **UTF-16** kodiert in einem oder zwei 16-Bit Wörtern. Geschieht die Kodierung nur in einem 16-Bit Wort, so entspricht die Kodierung der von UCS-2.
- **UTF-32** kodiert in einem 32-Bit Wort.



# Kodierungsalgorithmus für UTF-8

- Im Folgenden bezeichnet **xxx** die Nutzinformation
- Jedes mit einem **0-Bit beginnende Zeichen** enthält in den restlichen 7 Bit den ASCII-Code eines Zeichens: Muster: 0xxx xxxx.
- Besteht ein UTF-8 Code aus mehreren (n) Bytes, so beginnt das **erste Byte mit n 1-Bits und einer 0 und jedes Folgebyte beginnt mit der Bitfolge 10**. Beispielmuster: 110x xxxx 10xx xxxx.
- **2-Byte Codes** haben die Form 110x xxxx 10xx xxxx und ermöglichen die Abspeicherung UCS-2 Codes, die maximal 11 Bits benötigen.
- **3-Byte Codes** haben die Form 1110 xxxx 10xx xxxx 10xx xxxx und ermöglichen die Abspeicherung aller 16 Bit UCS-2 Codes.
- **4-Byte Codes** haben die Form 1111 0xxx 10xx xxxx ... und ermöglichen die Abspeicherung aller UCS-4 Codes.



# Zwischenstand

- Es existieren historisch gewachsen verschiedene Kodierungen für Zeichen
- Diese sind aufeinander aufbauend
- UTF-8 ist ein Komprimierungsverfahren optimiert auf häufig genutzte Zeichen

## Reflektion

- Welche Probleme treten auf, wenn man in einem Text verschiedene Kodierungen mischt?
- Was könnte/müsste man tun, um diese Probleme zu lösen?



# Einzelne Zeichen in Java

Datentyp	Anzahl Bits	Anzahl Bytes	Wertebereich
char	16	2	U+0000 bis U+FFFF bzw. 0-65536

- Der Datentyp `char` dient zur Darstellung **eines einzelnen Zeichens** in Java
- Mit der **internen Kodierung** kommt ein Programmierer (wenn er es nicht explizit möchte) kaum/nicht in Berührung
- Java verwendet UTF-16 mit einem 16-Bit Wort zur (internen) Kodierung von Zeichen
- `char` ist ein Zahlentyp (addieren, multiplizieren,...)
- Nur bei Ein-/Ausgabe und textspezifischen Methoden werden Werte als Repräsentationen von Zeichen interpretiert



# Zeichenliterale

- Ein Literal vom Typ `char` wird angegeben, indem man es in (einfache!) Hochkommata einschließt
- Beispiel: `'a'`, `'9'`, `'!'`
- Ausnahme innerhalb Kochkommas: siehe Tabelle
- U.a. dafür: Escape-Sequenzen der Form `'\x'`

Angabe	Bedeutung
<code>\'</code>	Hochkomma selber
<code>\\"</code>	Rückwärtsschrägstrich
<code>\b</code>	Backspace (Positionierung auf vorangehendes Zeichen)
<code>\t</code>	Tabulator
<code>\n</code>	Zeilenende (Line Feed)
<code>\r</code>	Zeilenende (Carriage Return)
<code>\f</code>	Seitenende
<code>\"</code>	Anführungszeichen
<code>\uxxxx</code>	Hexadezimalcode xxxx des Zeichens
<code>\ooo</code>	Sequenz von bis zu 3 Oktalziffern (Oktalcode des Zeichens)



# Beispiel

```
public class CharBeispiel2 {  
    public static void main(String[] args) {  
  
        // Definition dreier Variablen vom Typ char  
        char c1 = 'a';  
        char c2 = '\n';  
        char c3 = 'b';  
  
        // Ausgabe der drei Zeichen  
        System.out.println("") + c1 + c2 + c3);  
    }  
}
```

Ausgabe auf Bildschirm:

a  
b



# Zeichen werden intern wie Zahlen behandelt

- Der Compiler wandelt eine Angabe wie 'A' **automatisch in den intern genutzten Unicode um**, also einen ganzzahligen Wert
- Der interne Unicode kann **ähnlich wie ein int-Wert** behandelt werden (der Datentyp `char` gehört auch zu den numerischen Typen!)
- Wenn man zwei Codes voneinander abzieht, bekommt man den **Differenzbetrag als int-Wert**  
Beispiel: '9' - '0' = 9
- Wenn man **zu einem Zeichen/Code zum Beispiel einen int-Wert x addiert**, bekommt man den Code, der x Position weiter ist.  
**Aber:** an dieser Stelle muss ich eine Typanpassung (cast) des Resultatwertes vornehmen (Gründe und Details dazu später)  
Beispiel: (`char`) (9 + '0')



# Beispiel

```
public class CharBeispiel3 {  
  
    public static void main(String[] args) {  
        // Berechne Distanz zweier Codes  
        char c = '9';  
        int wert = c - '0';  
        System.out.println("Der Wert der Ziffer " + c + " ist " + wert);  
  
        // Rechne mit Code (hier addieren)  
        wert = 9;  
        c = (char) (wert + '0');  
        System.out.println("Die Ziffer zum Wert " + wert + " ist " + c);  
    }  
}
```

## Ausgabe auf Bildschirm:

Der Wert der Ziffer 9 ist 9

Die Ziffer zum Wert 9 ist 9



# Zwischenstand

- Variablen des Datentyps `char` können genau ein Zeichen aufnehmen
- Zeichenkonstanten werden in Apostrophe eingeschlossen
- Es gibt Escape-Sequenzen für Zeichen „außerhalb der Tastatur“
- Mit Zeichen kann man „rechnen“

## Reflektion

- Würde ein Ausdruck wie `'A' + 0.5` auch Sinn machen? Wieso / wieso nicht?



# Zeichenketten / Strings

- Meist ist man nicht nur an einem einzigen Zeichen interessiert, sondern an einer ganzen **Folge von Zeichen**
- Eine Folge von Zeichen wird als **String** bezeichnet
- Ein String kann leer sein, kann genau ein Zeichen enthalten oder viele Zeichen enthalten
- Strings spielen eine wichtige Rolle, insbesondere **in der kommerziellen Welt**



# Strings in Java

- Achtung: es gibt **keinen primitiven Datentyp für Strings** in Java
- Es gibt statt dessen eine **Klasse mit Namen String**, über die mit Strings gearbeitet werden kann
- Das hat **große Konsequenzen**, auf die wir später zurück kommen werden
- In vielerlei Hinsicht verwendet man Strings aber analog zu Daten primitiver Typen
- **String-Konstanten:** Folge von Zeichen inklusive Escape-Sequenzen **in (doppelten) Anführungszeichen**
- **Beispiele:** "hallo" , "", "A" , "neue Zeile\nist hier"
- **Vorsicht:** "A" ist vom Typ String, 'A' ist vom Typ char
- **Deklaration einer Stringvariablen** analog zu vorher: `String str;`



# Operationen auf Strings

- Einfachste Operation ist neben der Zuweisung das **Aneinanderhängen von Strings mit +**
- **Beispiel:** "abc" + "def" ergibt den String "abcdef"
- Das Ergebnis ist ein **neuer String** mit dem zusammengefügten Inhalt der beiden alten Strings!
- Es wird in Java also **nicht** ein existierender String erweitert/verändert!
- Wenn ein Argument des binären Plus-Operators ein String ist, wird das andere Argument **automatisch in einen String umgewandelt** (aber später auch zu beachten: Priorität von Operatoren)
- **Beispiele:**
  - "abc" + 3 ergibt "abc3"
  - 3 + "abc" ergibt "3abc"
- Weiterhin gibt es **Operationen nur im Zusammenhang mit einem String** (Achtung: hier sieht man schon den Unterschied zu primitiven Datentypen)
- **Beispiel:** "abc".length()



# Methoden auf Strings

Methodename	Beispiel	Ergebnis	Bedeutung
equals (str)	"abc".equals ("bcd")	false	Vergleich zweier Strings (kein == )
charAt (i)	"abc".charAt (1)	'b'	Zeichen an der i-ten Position
indexOf (c)	"abc".indexOf ('b')	1	erste Position des Zeichens
length ()	"abc".length ()	3	Länge des Strings in Zeichen
substring (x, y)	"abc".substring (1, 2)	"b"	Teilstring von Position x bis y

- Alle Methoden nur im Zusammenhang mit einem String (siehe Beispiele oben)
- Statt Stringkonstanten können natürlich auch Stringvariablen dabei genutzt werden (allgemein: beliebige Ausdrücke vom Typ String)
- Positionen beginnen bei 0
- Fehlerquelle: Strings können nicht mit == auf gleichen Inhalt verglichen werden
- Viele weitere Stringmethoden vorhanden (siehe Dokumentation Klasse String in der API-Dokumentation)



# Beispiel

```
public class StringBeispiel3 {  
    public static void main(String[] args) {  
  
        // Definition einer Variablen vom Typ String  
        String s = "01234567689";  
  
        // bestimme Laenge des Strings  
        int len = s.length();  
  
        // extrahiere den Teilstring ohne erstes und letztes Zeichen  
        s = s.substring(1, len-1);  
  
        // fuege vorne und hinten Zeichen an  
        s = "->" + s + "<-";  
  
        System.out.println(s);  
    }  
}
```

Ausgabe auf Bildschirm:

->123456768<-



# Zwischenstand

- Der Datentyp `String` ist kein primitiver Datentyp
- Variablen des Datentyps `String` können beliebig viele Zeichen aufnehmen inklusive leerer String
- Stringkonstanten werden zwischen Anführungszeichen angegeben
- Der `+` Operator mit 2 Strings erzeugt einen neuen String mit den aneinandergehängten Inhalten der beiden Argument-Strings
- In der Klasse `String` gibt es viele Methoden zur Verarbeitung von Strings

## Reflektion

- Welche Vor-/Nachteile könnte es haben, wenn beim `+` Operator ein neuer String entsteht? Alternativ könnte man ja auch das erste Argument verändern?



# Zusammenfassung

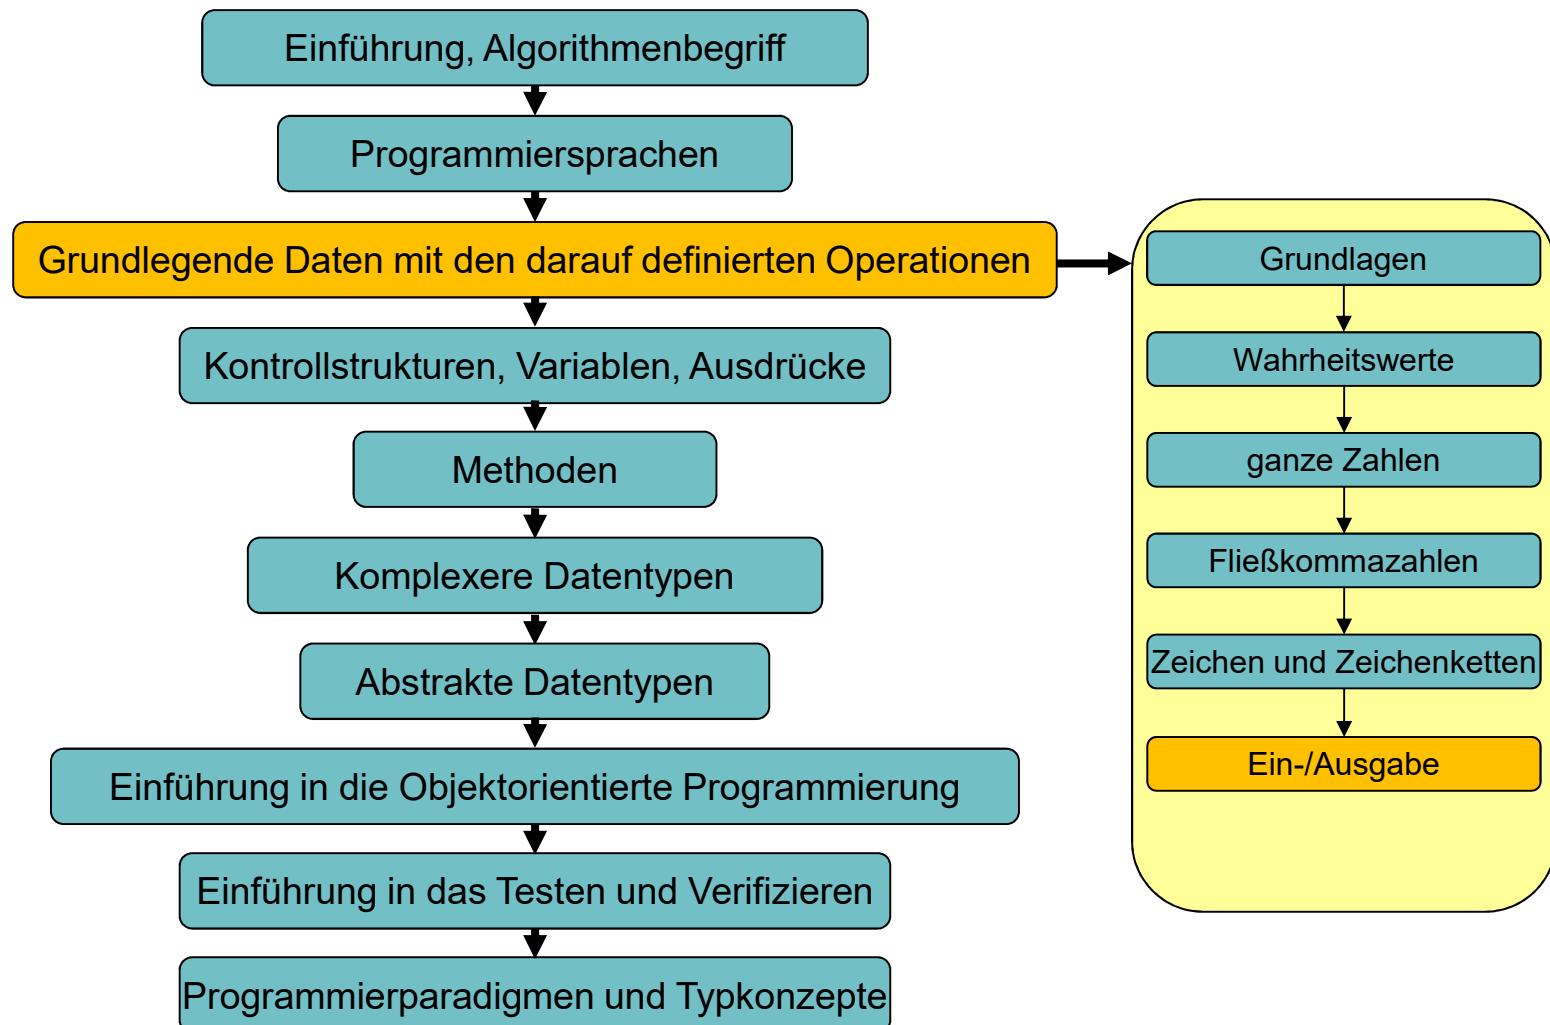
- Datentyp `char` für ein Zeichen, die Klasse `String` für Zeichenketten
- Kodierung von Zeichen durchgehend `in Unicode`
- Zahlreiche Operationen auf Strings über Methoden möglich
- Steckbrief zu Zeichen und Zeichenketten

Name	<code>char</code>
Wertemenge	Zeichen
Kodierung	UCS-2
Konstanten	ein Zeichen in Apostrophen ' <code>...</code> '
Operationen	Zuweisung, Vergleichsoperatoren, Zeichenmethoden, arithmetische Operationen wie <code>int</code> (automatische Umwandlung)
Nutzung	für genau ein Zeichen
Besonderheiten	

Name	<code>String</code>
Wertemenge	Zeichenfolgen
Kodierung	UTF-16
Konstanten	beliebig viele Zeichen in Anführungszeichen " <code>...</code> "
Operationen	Zuweisung, <code>+</code> , Stringmethoden
Nutzung	für Zeichenketten
Besonderheiten	kein primitiver Datentyp



# Inhalt dieser Veranstaltung



# Einfache Ein-/Ausgabe von Daten

- Bisher:
  - Ausgabe von Daten mit `System.out.println(...);`
  - Eingabe von Daten: -
- Jetzt: wie kann man in einem Programmlauf **Daten einlesen**, die zur Übersetzungszeit noch nicht vorhanden sind?
- **Zwei einfache Antworten** für diese Veranstaltung:
  - Daten über die Tastatur eingeben bei Aufruf des Programms  
**Formulierung in Aufgaben:** „...in der Kommandozeile übergeben...“
  - Daten über die Tastatur eingeben, während das Programm läuft  
**Formulierung in Aufgaben:** „...von der Tastatur einlesen...“
- Java kennt das **umfangreiche Stream-Konzept**, mit dem sich flexibel Daten ein- und ausgeben lassen (Dateien, Netzwerk, Webseiten,...; nicht in dieser Veranstaltung)



# Daten bei Programmstart übergeben

- Beim Start eines Programms kann man **in der Kommandozeile** Daten an das Programm übergeben
- **Formulierung dazu in Aufgaben / Prüfung: in der Kommandozeile**
- Dies geschieht implizit in eclipse
- Bei Start eines Java-Programms
  - **in der Kommandozeile:** java MeinProgramm 1 2.0 drei
  - In **eclipse** über Menü Run, dann Run Configurations, dann (x) =Arguments
- Im Programm kann man auf diese Daten als Strings zugreifen
- Dazu dient `args` in `public static void main(String[] args)`
- `args` ist ein Vektor (später: ein Feld) von Strings, `args[i]` der i-te String
- **Umwandeln eines Strings in einen Wert** (falls Syntax korrekt) geschieht über spezielle Umwandlungsmethoden (siehe nachfolgendes Beispiel)
- Man muss dabei den Zieltyp wissen



# Beispiel

```
/* Aufruf des Programms zum Beispiel mit:  
   java Kommandozeilenargumente 1 2 3 4 5.7 3.1 x str  
   Das i-te Argument muss mit der entsprechenden Operation lesbar seinpublic class Kommandozeilenargumente {  
    public static void main(String[] args) {  
        // 1. Argument muss eine ganze Zahl im Wertebereich byte sein  
        byte b = Byte.parseByte(args[0]);  
        // 2. Argument muss eine ganze Zahl im Wertebereich short sein  
        short s = Short.parseShort(args[1]);  
        // 3. Argument muss eine ganze Zahl im Wertebereich int sein  
        int i = Integer.parseInt(args[2]);  
        // 4. Argument muss eine ganze Zahl im Wertebereich long sein  
        long l = Long.parseLong(args[3]);  
        // 5. Argument muss eine Fließkommazahl im Wertebereich float sein  
        float f = Float.parseFloat(args[4]);  
        // 6. Argument muss eine Fließkommazahl im Wertebereich double sein  
        double d = Double.parseDouble(args[5]);  
        // 7. Argument muss ein Character sein  
        char c = args[6].charAt(0);  
        // 8. Argument muss ein String sein  
        String str = args[7];  
    }  
}
```



# Einlesen von Daten während des Programmlaufs

- An dieser Stelle pragmatische Erklärung, weniger Hintergrunddetails
- **Formulierung in Aufgaben / Prüfung: von der Tastatur (zur Laufzeit)**
- Mit einem Programm sind **zwei Ein- und Ausgabedateien** vordefiniert
- Für die Ausgabe: `System.out`
- Für die Eingabe: `System.in`
- Mit Hilfe eines `Scanner` lassen sich darüber Daten von der Tastatur während eines Programmlaufs einlesen
- **Zu beachten:** die Leseoperationen sind blockierend (sie warten, bis die Eingabe erfolgt ist, abgeschlossen durch ↵ / Return)



# Beispiel

```
import java.util.*;          // hier kommt der Scanner her
public class EingabeTastatur {
    public static void main(String[] args) {
        // Scanner von der Tastatur anlegen
        Scanner sc = new Scanner(System.in);

        System.out.println("Geben Sie Daten folgender Typen auf der Tastatur ein: "
                           + "byte, short, int, long, float, double, "
                           + "char (eigene Zeile), String (eigene Zeile)");
        // Daten ueber den Scanner lesen
        byte b = sc.nextByte();
        short s = sc.nextShort();
        int i = sc.nextInt();
        long l = sc.nextLong();
        float f = sc.nextFloat();
        double d = sc.nextDouble();
        String s1 = sc.next();
        char c = s1.charAt(0);
        String s2 = sc.next();
        // eingelesene Daten ausgeben
        System.out.println("Die eingelesenen Werte sind: " + b + " "
                           + s + " " + i + " " + l + " " + f + " " + d + " " + c + " " + s2);
        // Scanner abschliessen
        sc.close();
    }
}
```



# Zusammenfassung

- Zwei sehr einfache Möglichkeiten der **Eingabe von Daten**:
  - Beim Programmstart über die Kommandozeile
  - Zur Laufzeit des Programms über `System.in` und einen Scanner
- Später sollten sinnvollerweise die erweiterten Möglichkeiten **der Streams** und **weiterer Ansätze in Java** genutzt werden

