


Technische Informatik

Datencodierung



Grundbegriffe

- Zeichenvorräte und Codierung sind prinzipiell willkürliche Vereinbarungen, die für die jeweilige Anwendung optimiert werden

<i>Zeichenvorrat</i>	Eine endliche Menge von Zeichen
<i>Alphabet</i>	Ein geordneter Zeichenvorrat
<i>Wort</i>	Eine endliche Folge von Zeichen eines Alphabets (Zeichenkette)
<i>Codierung</i>	Funktion (Abbildungsvorschrift), die die Elemente eines Zeichenvorrates A abbildet auf Wörter über einen anderen Zeichenvorrat B . Die Codierung kann z.B. durch eine <i>Codetabelle</i> oder eine <i>Umwandlungsvorschrift</i> beschrieben werden.
<i>Codewort</i>	Element des Bildbereiches B der Codierung
<i>Code</i>	Menge aller Codewörter
<i>Binärcode</i>	Codierung mit dem Bildbereich B = {0, 1} (Der Zeichenvorrat des Bildbereiches umfasst genau zwei Zeichen). Wird eine feste Codewortlänge n verwendet, liegt eine <i>n-Bit-Codierung</i> vor

- Optimalcodierung
 - Minimaler Zeichenaufwand
- Systematische Codes
 - Enthalten Redundanzen zur Fehlererkennung und -korrektur
 - Vergl. *Hamming-Distanz* (= Anzahl der Stellen, in denen sich zwei Codeworte unterscheiden)
- Zyklische und lineare Codes
 - Systematische Codes, bei denen die Verknüpfung zweier gültiger Codeworte wieder ein gültiges Codewort ergibt
- Übliche Wortbreiten binärer Codierung:
 - Byte 8 Bit
 - Word 16 Bit (high byte + low byte)
 - Doubleword 32 Bit (high word + low word)
 - Quadword 64 Bit (high doubleword + low doubleword)

Vorzeichenlose Ganzzahl: Dualsystem

- Dualsystem

- Stellenwertsystem mit der Basis 2
- Die i-te Ziffer von rechts (x_i) hat die Wertigkeit 2^i

Ziffer	x_7	x_6	x_5	x_4	x_3	x_2	x_1	x_0
Wertigkeit	2^7 = 128	2^6 = 64	2^5 = 32	2^4 = 16	2^3 = 8	2^2 = 4	2^1 = 2	2^0 = 1

- Codierung:

$$X = x_{N-1} \cdot 2^{N-1} + x_{N-2} \cdot 2^{N-2} + \dots + x_1 \cdot 2^1 + x_0 \cdot 2^0$$

Codetabelle:

Dezimal	Dual		
	x_2	x_1	x_0
0	0	0	0
1	0	0	1
2	0	1	0
3	0	1	1
4	1	0	0
5	1	0	1
6	1	1	0
7	1	1	1

- Beispiel:

$$75_{dez} = 0 \cdot 2^7 + 1 \cdot 2^6 + 0 \cdot 2^5 + 0 \cdot 2^4 + 1 \cdot 2^3 + 0 \cdot 2^2 + 1 \cdot 2^1 + 1 \cdot 2^0 = 0100\ 1011_{bin}$$

- Anmerkung:

- Anwendbar für natürliche Zahlen (ohne Vorzeichen)
- Verschiedene Wortbreite
- Carry (Übertrag): $000\dots0_{bin} \leftrightarrow 111\dots1_{bin}$

Vorzeichenlose Ganzzahl: Oktal- und Hexadezimalsystem

- Oktalsystem:

- Stellenwertsystem mit der Basis 8
- Zeichenvorrat = {0,1,2,3,4,5,6,7}

Ziffer	x ₃	x ₂	x ₁	x ₀
Wertigkeit	8 ³ = 512	8 ² = 64	8 ¹ = 8	8 ⁰ = 1

- Hexadezimalsystem:

- Stellenwertsystem mit der Basis 16
- Zeichenvorrat = {0,1,2,3,4,5,6,7,8,9,A,B,C,D,E,F}

Ziffer	x ₃	x ₂	x ₁	x ₀
Wertigkeit	16 ³ = 4096	16 ² = 256	16 ¹ = 16	16 ⁰ = 1

- Beispiel:

dezimal	156							
dual	1	0	0	1	1	1	0	0
hexadezimal	9				C			

$$156 = 1*128 + 1*16 + 1*8 + 1*4$$

$$156 = 9*16 + 12*1$$

- Anmerkung:

- Eine Dualzahl kann in eine Hexadezimalzahl umgewandelt werden, indem jeweils 4 Bit zusammengefasst werden. Entsprechendes gilt für die Oktalzahl (3 Bit)

Vorzeichenbehaftete Ganzzahl: Offset-Dual-Darstellung

- Offset-Dual-Darstellung (binary offset, biased dual)

- Abgeleitet vom Dualsystem
- Subtraktion der größten Wertigkeit

- Codierung:

$$X = x_{N-1} \cdot 2^{N-1} + \dots + x_1 \cdot 2^1 + x_0 \cdot 2^0 - \underline{2^{N-1}}$$

- Beispiel:

$$-53_{dez} = 0 \cdot 2^7 + 1 \cdot 2^6 + 0 \cdot 2^5 + 0 \cdot 2^4 + 1 \cdot 2^3 + 0 \cdot 2^2 + 1 \cdot 2^1 + 1 \cdot 2^0 - 2^7 = 01001011_{bin}$$

Codetabelle:

Dezimal	Offset-Dualzahl		
	x ₂	x ₁	x ₀
-4	0	0	0
-3	0	0	1
-2	0	1	0
-1	0	1	1
0	1	0	0
1	1	0	1
2	1	1	0
3	1	1	1

Vorzeichenbehaftete Ganzzahl: Betrag und Vorzeichen

- Darstellung mit Betrag und Vorzeichen

- Abgeleitet vom Dualsystem
- Höchstwertiges Bit (MSB) liefert das Vorzeichen
(Vorzeichenbit: 0 = positiv, 1 = negativ)
- Die Zahl 0 wird zweimal codiert („+0“ und „-0“)
- Eindeutige Interpretation nur bei fester Wortbreite

- Codierung:

$$X = \underline{(-1)^{x_{N-1}}} \cdot (x_{N-2} \cdot 2^{N-2} + \dots + x_1 \cdot 2^1 + x_0 \cdot 2^0)$$

- Beispiel:

$$-11_{dez} = (-1)^1 \cdot (0 \cdot 2^6 + 0 \cdot 2^5 + 0 \cdot 2^4 + 1 \cdot 2^3 + 0 \cdot 2^2 + 1 \cdot 2^1 + 1 \cdot 2^0) = 10001011_{bin}$$

Codetabelle:

Dezimal	Dualzahl mit Vorzeichenbit		
	x ₂	x ₁	x ₀
+0	0	0	0
1	0	0	1
2	0	1	0
3	0	1	1
-0	1	0	0
-1	1	0	1
-2	1	1	0
-3	1	1	1

Vorzeichenbehaftete Ganzzahl: Einerkomplement

- Einerkomplement

- Abgeleitet vom Dualsystem
- Eine negative Zahl wird durch das bitweise Komplement der entsprechenden positiven Zahl dargestellt
- Vorzeichenwechsel:
 - Invertierung aller Bits

Keine praktische Anwendung!

- Codierung:

$$X = \underline{-}x_{N-1} \cdot (2^{N-1} - 1) + x_{N-2} \cdot 2^{N-2} + \dots + x_0 \cdot 2^0$$

- Beispiel:

$$-7_{dez} = -1 \cdot (2^7 - 1) + 1 \cdot 2^6 + 1 \cdot 2^5 + 1 \cdot 2^4 + 1 \cdot 2^3 + 0 \cdot 2^2 + 0 \cdot 2^1 + 0 \cdot 2^0 = 11111000_{bin}$$

- Anmerkung:

- Die Zahl 0 wird zweimal codiert („+0“ und „-0“)
- Bei Addition/Subtraktion muss Vorzeichen als Sonderfall berücksichtigt werden

Codetabelle:

Dezimal	Einerkomplement		
	x ₂	x ₁	x ₀
+0	0	0	0
1	0	0	1
2	0	1	0
3	0	1	1
-3	1	0	0
-2	1	0	1
-1	1	1	0
-0	1	1	1

Vorzeichenbehaftete Ganzzahl: Zweierkomplement

- Zweierkomplement

- Abgeleitet vom Dualsystem
- Standarddarstellung für Rechnersysteme
- Höchstwertiges Bit (MSB) hat *negative* Wertigkeit
- Vorzeichenwechsel:
 - Invertierung aller Bits und Addition einer „1“

- Codierung:

$$X = -x_{N-1} \cdot 2^{N-1} + x_{N-2} \cdot 2^{N-2} + \dots + x_0 \cdot 2^0$$

- Beispiel:

$$-7_{dez} = -1 \cdot 2^7 + 1 \cdot 2^6 + 1 \cdot 2^5 + 1 \cdot 2^4 + 1 \cdot 2^3 + 0 \cdot 2^2 + 0 \cdot 2^1 + 1 \cdot 2^0 = 11111001_{bin}$$

- Anmerkung:

- Keine getrennte Betrachtung des Vorzeichens bei Addition bzw. Subtraktion
- **overflow (Überlauf):** $011\dots1_{bin} \leftrightarrow 100\dots0_{bin}$

Codetabelle:

Dezimal	Zweierkomplement		
	x ₂	x ₁	x ₀
0	0	0	0
1	0	0	1
2	0	1	0
3	0	1	1
-4	1	0	0
-3	1	0	1
-2	1	1	0
-1	1	1	1

Binär Codierte Dezimalzahl (BCD)

- Binär Codierte Dezimalzahl:

- Jede Ziffer einer Dezimalzahl wird auf eine 4-Bit Binärzahl abgebildet (8421-BCD).
- Die „Pseudotetraden“ 1010_{bin} bis 1111_{bin} werden i.d.R. nicht verwendet
- Auf beliebig viele Stellen erweiterbar

- Beispiel:

<i>dezimal</i>	3				7			
<i>BCD</i>	0	0	1	1	0	1	1	1

- Anwendung:

- Finanzmathematik
- Real-Time-Clock (Mikrocontroller)
- 7-Segment-Anzeige

Codetabelle:

<i>Dezimal</i>	<i>BCD</i>			
	x_3	x_2	x_1	x_0
0	0	0	0	0
1	0	0	0	1
2	0	0	1	0
3	0	0	1	1
4	0	1	0	0
5	0	1	0	1
6	0	1	1	0
7	0	1	1	1
8	1	0	0	0
9	1	0	0	1

Gray-Code

- Gray-Code:
 - Bei jedem Übergang von einer Zahl zur nächsten ändert sich genau ein Bit
 - Für arithmetische Operationen ungeeignet
- Anwendung:
 - Winkel- oder Längencodierung in der Messtechnik

Codetabelle:

Dezimal	Gray-Code		
	x ₂	x ₁	x ₀
0	0	0	0
1	0	0	1
2	0	1	1
3	0	1	0
4	1	1	0
5	1	1	1
6	1	0	1
7	1	0	0

Festkommazahlen

- Festkommazahlen

- Abgeleitet vom Dualsystem
- Feste Anzahl M der Nachkommastellen
- Die i-te Stelle hat die Wertigkeit 2^{i-M}

Ziffer	x_{N-1}	x_{N-2}	...	x_M	x_{M-1}	x_2	...	x_0
Wertigkeit	2^{N-M-1}	2^{N-M-2}	...	2^0	2^{-1} $= 1/2$	2^{-2} $= 1/4$...	2^{-M}

- Negative Zahlen mit Betrag und Vorzeichen oder als Zweierkomplement darstellbar

- Codierung:

$$X = x_{N-1} \cdot 2^{N-1-M} + \dots + x_M \cdot 2^0 + x_{M-1} \cdot 2^{-1} + \dots + x_0 \cdot 2^{-M}$$

- Beispiel:

$$14/8 = 1.75_{dez} = 0 \cdot 2^3 + 0 \cdot 2^2 + 0 \cdot 2^1 + 1 \cdot 2^0 + 1 \cdot 2^{-1} + 1 \cdot 2^{-2} + 0 \cdot 2^{-3} = 00001.110_{bin}$$

Codetabelle:

Dezimal	Festkommazahl M = 2, ohne VZ		
	x ₂	x ₁	x ₀
0.00	0	0	0
0.25	0	0	1
0.50	0	1	0
0.75	0	1	1
1.00	1	0	0
1.25	1	0	1
1.50	1	1	0
1.75	1	1	1

Gleitkommazahlen


- Gleitkommazahlen
 - Standard: IEEE 754
 - Eine Gleitkommazahl X besteht aus *Vorzeichen S*, *Mantisse M* und *Exponent E*

$$X = S \cdot M \cdot 2^E$$


- Normalisierte Darstellung
 - für die Mantisse M gilt: $1 \leq M < 2$
 - d.h.: M hat die Form $1.m_{k-1}m_{k-2}\dots m_0$
 - Folge: Die „1“ vor dem Komma muss nicht gespeichert werden (*hidden bit*)
- Denormalisierte Darstellung
 - Wird zur verbesserten Darstellung sehr kleiner Zahlen verwendet
 - M hat die Form $0.m_{k-1}m_{k-2}\dots m_0$
 - E = 0

Gleitkommazahlen

- Binärformate:
 - Vorzeichen (1 Bit): 0 = positiv, 1 = negativ
 - Mantisse (k Bit): M-1 als Festkommazahl mit k Nachkommastellen
 - Exponent: (j Bit): Offset-Dualzahl ($\text{Offset} = 2^{j-1} - 1$)
- Binärdarstellung (hier: 32-Bit):



- Beispiel:



$$S = (-1)^1 = -1$$

$$E = 1 \cdot 2^7 + 1 \cdot 2^1 - (2^7 - 1) = 130 - 127 = 3$$

$$M = 1 + 1 \cdot 2^{-1} + 1 \cdot 2^{-3} + 1 \cdot 2^{-4} = 1 + 0,6875$$

$$\Rightarrow X = -1 \cdot 1,6875 \cdot 2^3 = -13,5$$

Gleitkommazahlen

- Standardformate nach IEEE 754:

Format	Genauigkeit	Exponent Größe	Exponent Bereich	Mantisse Größe
single precision	32-bit	8 Bit	$10^{\pm 38}$	23+1 Bit
double precision	64-bit	11 Bit	$10^{\pm 308}$	52+1 Bit
intern	80-bit	16 Bit	$10^{\pm 4932}$	63+1 Bit

- Sonderfälle:

Typ	Exponent	Mantisse	Wert
<i>infinity</i>	$2^j - 1$ (alle Bits = 1)	= 0	unendlich
<i>NAN</i> (not a number)	$2^j - 1$ (alle Bits = 1)	$\neq 0$	nicht definiert
<i>zero</i>	0	= 0	0
<i>denormalized</i>	0	$\neq 0$	zwischen 0 und kleinster normalisierten Zahl

Gleitkommazahlen

- Interne Berechnungen:
 - Denormalisierte Darstellung mit höherer Genauigkeit
- Addition:
 - Angleichung des kleineren an den größeren Exponenten (erfordert Entnormalisierung)
 - Addition der Mantissen
 - Normalisierung des Ergebnisses
- Multiplikation:
 - Multiplikation der Vorzeichen
 - Multiplikation der Mantissen
 - Addition der Exponenten
 - Normalisierung des Ergebnisses

Alphanumerische Zeichen

- Alphanumerische Zeichen werden durch Code-Tabellen codiert
- ASCII (American Standard Code for Information Interchange)
 - Enthält 128 Zeichen (7 Bit)
 - Die ersten 32 Zeichen sind Steuerzeichen für Textausgabegeräte, z.B.:
 - 'HT' = Horizontal Tab
 - 'LF' = Line Feed
 - 'CR' = Carriage Return,
 - Verschiedene Erweiterungen mit 8 Bit (Zeichen 128 bis 255)
 - Unterstützen verschiedene Zeichensätze und sprachspezifische Buchstaben
 - z.B. ISO 646, Codepage 437, ISO 8859,..
- Unicode
 - Einheitliche und umfassende Codierung für alle relevanten Schriftzeichen
 - 8-, 16- oder 32-Bit-Darstellung, organisiert in 17 Ebenen mit je 2^{16} Zeichen
 - UTF-8 (8-Bit Unicode Transformation Format) ist eine Teilmenge des Unicodes und abwärtskompatibel zu ASCII

ersetzt
durch

Alphanumerische Zeichen

- ASCII-Tabelle:

Code	-0	-1	-2	-3	-4	-5	-6	-7	-8	-9	-A	-B	-C	-D	-E	-F
0-	NUL	SOH	STX	ETX	EOT	ENQ	ACK	BEL	BS	HT	LF	VT	FF	CR	SO	SI
1-	DLE	DC1	DC2	DC3	DC4	NAK	SYN	ETB	CAN	EM	SUB	ESC	FS	GS	RS	US
2-	SP	!	"	#	\$	%	&	'	()	*	+	,	-	.	/
3-	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4-	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5-	P	Q	R	S	T	U	V	W	X	Y	Z	[\]	^	_
6-	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7-	p	q	r	s	t	u	v	w	x	y	z	{		}	~	DEL

- Die ersten 32 und das letzte Zeichen (Code 00H bis 1FH und 7FH) sind nicht darstellbare Steuerzeichen, SP (Code 20H) ist das Leerzeichen

- Beispiel:

<u>Schriftzeichen</u>	<u>dezimal</u>	<u>hexadezimal</u>	<u>dual</u>
A	65	41	0100 0001
{	123	7B	0111 1011